

# 北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

# 神经网络与深度学习

## 课程实验报告

## 基于 NumPy 的全连接神经网络图像分类实验

A1 全连接神经网络图像分类


姓　名　罗开炜

学　号　2024211735

学　院　人工智能学院

班　级　2024219112


2026 年 10 月

# 摘　要

本实验使用 NumPy 自主实现双隐藏层全连接神经网络及反向传播，完成 MNIST 手写数字与 CIFAR-10 图像分类。实验比较五类损失函数、L1/L2/Dropout 正则化、七类优化器以及 Batch 策略。MNIST 和 CIFAR-10 基准测试准确率分别为 96.83% 和 50.39%；MNIST Hinge 与 Nesterov 代表模型分别达到 97.63% 和 97.98%。结果显示，优化器与学习率共同影响收敛；正则化并不总能提高准确率；展平像素 MLP 在 CIFAR-10 上仍有明显泛化差距。报告结合真实记录分析各方法差异，结论限于本次网络和训练设置。

**关键词：** 多层感知机；NumPy；图像分类；反向传播；优化算法

# 目录

**第一章 实验目的与任务** **1**

**第二章 理论基础与系统实现** **1**

2.1 MLP 与前向传播 . . . . . 1
2.2 损失函数与反向传播 . . . . . 1
2.3 正则化与优化算法 . . . . . 2
2.4 NumPy 系统实现 . . . . . 3

**第三章 实验设置** **4**

3.1 数据集与预处理 . . . . . 4
3.2 网络结构与训练参数 . . . . . 4
3.3 对照设计与评价指标 . . . . . 4

**第四章 实验结果与分析** **5**

4.1 基准实验 . . . . . 5
4.2 损失函数对照 . . . . . 6
4.3 正则化对照 . . . . . 8
4.4 优化算法对照 . . . . . 9
4.5 Batch 策略比较 . . . . . 10
4.6 CIFAR-10 扩展与简要讨论 . . . . . 10

**第五章 总结** **13**

**参考文献** **14**

**附录 A 复现资料与 AI 辅助说明** **15**

# 第一章　实验目的与任务

图像分类是理解神经网络训练过程的常见任务。本次《神经网络与深度学习》课程 A1 作业要求使用 NumPy 自主实现全连接神经网络，并在 MNIST 或 CIFAR-10 数据集上完成图像分类。本实验在此基础上同时使用 MNIST 和 CIFAR-10，进一步比较不同训练方法的效果。实验采用 NumPy 数组运算实现前向传播、反向传播和参数更新，不使用深度学习框架的自动求导，以便将链式法则与实际梯度计算对应起来 [1, 2]。

本次实验使用两个隐藏层的多层感知机（Multilayer Perceptron，MLP），以展平像素作为输入。主要内容包括：完成数据预处理与训练评估流程；实现交叉熵等五类损失函数；比较 L1、L2、Dropout 及组合正则化；比较七类优化器与不同 Batch 策略；分析 CIFAR-10 代表性扩展配置和少量多随机种子结果。

报告重点展示手写梯度的实现依据、实际分类效果以及方法对照中的差异。实验记录已在项目中保存。下面先说明理论与实现，再介绍实验设置、结果和结论。

# 第二章　理论基础与系统实现

## 2.1　MLP 与前向传播

MLP 由全连接层和非线性激活组成。本文使用两个 ReLU 隐藏层，输出层给出十类未归一化分数（logits）。设批大小为 $B$，第 $l$ 层输入按样本排列为 $\boldsymbol{A}^{(l-1)} \in \mathbb{R}^{B\times d_{l-1}}$，权重为 $\boldsymbol{W}^{(l)} \in \mathbb{R}^{d_{l-1}\times d_l}$，则

$$\boldsymbol{Z}^{(l)} = \boldsymbol{A}^{(l-1)}\boldsymbol{W}^{(l)} + \mathbf{1}_B(\boldsymbol{b}^{(l)})^{\mathsf{T}}, \tag{2.1}$$

$$\boldsymbol{A}^{(l)} = \mathrm{ReLU}(\boldsymbol{Z}^{(l)}), \quad l = 1, \ldots, L-1. \tag{2.2}$$

其中 $\boldsymbol{A}^{(0)} = \boldsymbol{X}$，$\mathbf{1}_B$ 为全一列向量；输出层仅做仿射变换，记 $\boldsymbol{Z} = \boldsymbol{Z}^{(L)}$。ReLU 定义及导数为

$$\mathrm{ReLU}(x) = \max(0, x), \qquad \mathrm{ReLU}'(x) = \begin{cases} 1, & x > 0, \\ 0, & x \le 0. \end{cases} \tag{2.3}$$

隐藏层采用 Kaiming 正态初始化，权重方差为 $2/d_{l-1}$[3]；输出层采用 Xavier 正态初始化，方差为 $2/(d_{L-1} + d_L)$[4]，偏置初始化为零。

## 2.2　损失函数与反向传播

Softmax 将第 $i$ 个样本的分数转为类别概率，真实类别为 $t_i$ 时，批平均交叉熵（CE）为

$$p_{ij} = \frac{e^{z_{ij}}}{\sum_k e^{z_{ik}}}, \qquad \mathcal{L}_{\mathrm{CE}} = -\frac{1}{B}\sum_{i=1}^{B} \log p_{i,t_i}. \tag{2.4}$$

计算时先减去每行 logits 最大值，再求指数与对数，避免指数溢出。设 $\boldsymbol{Y}$ 为独热标签矩阵，交叉熵对输出分数的梯度为

$$\boldsymbol{D}^{(L)} = \frac{\partial \mathcal{L}_{\mathrm{CE}}}{\partial \boldsymbol{Z}} = \frac{\boldsymbol{P} - \boldsymbol{Y}}{B}. \tag{2.5}$$

令 $\boldsymbol{D}^{(l)} = \partial \mathcal{L} / \partial \boldsymbol{Z}^{(l)}$，全连接层与隐藏层的关键梯度为

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{W}^{(l)}} = (\boldsymbol{A}^{(l-1)})^{\mathsf{T}} \boldsymbol{D}^{(l)}, \tag{2.6}$$

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{b}^{(l)}} = (\boldsymbol{D}^{(l)})^{\mathsf{T}} \mathbf{1}_B, \tag{2.7}$$

$$\boldsymbol{D}^{(l-1)} = \left[\boldsymbol{D}^{(l)} (\boldsymbol{W}^{(l)})^{\mathsf{T}}\right] \odot \mathbb{I}(\boldsymbol{Z}^{(l-1)} > 0), \quad l \geq 2. \tag{2.8}$$

$\odot$ 表示逐元素乘法。前向传播保存各层输入和激活掩码，反向传播按层逆序计算。式(2.5)已包含批平均系数，全连接层不再次除以 $B$。全部梯度计算结束后才更新参数。

其余损失改变输出梯度，网络各层仍复用式(2.8)的传播过程。五类训练目标见表2.1；各自的原始损失尺度不同，实验统一使用准确率和真实标签 CE 评价。

表 2.1　损失函数及本实验的使用方式

| 损失 | 基本思想与参数 |
|---|---|
| CE | 提高真实类别概率，作为基准训练目标。 |
| Softmax-MSE | 最小化 $\frac{1}{2B}\sum_{i,j}(p_{ij}-y_{ij})^2$；梯度需经过 Softmax Jacobian，不能直接使用 CE 梯度。 |
| 标签平滑 CE | 将标签改为 $q_{ij}=(1-\epsilon)y_{ij}+\epsilon/C$，$\epsilon=0.1$；输出梯度为 $(\boldsymbol{P}-\boldsymbol{Q})/B$。 |
| 多类 Hinge | 惩罚 $\max(0, z_{ij}-z_{i,t_i}+\Delta)$，$j\neq t_i$，$\Delta=1$；真实类别梯度为有效错误类别梯度之和的相反数。 |
| Focal | 在 CE 上乘 $(1-p_{i,t_i})^{\gamma}$，$\gamma=2, \alpha=1$；求导同时考虑调制因子的变化 [5]。 |

## 2.3　正则化与优化算法

L1 和 L2 在数据损失之外加入权重惩罚：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + \lambda_1 \sum_l \|\boldsymbol{W}^{(l)}\|_1 + \frac{\lambda_2}{2} \sum_l \|\boldsymbol{W}^{(l)}\|_F^2. \tag{2.9}$$

相应梯度为 $\lambda_1 \operatorname{sign}(\boldsymbol{W})$ 和 $\lambda_2 \boldsymbol{W}$，仅作用于权重，不惩罚偏置。L1 的零点次梯度取零，同时使用 L1/L2 称为 Elastic Net。本文 L2 显式加入梯度，属于耦合权重惩罚。

Dropout 在训练时随机屏蔽隐藏激活 [6]。丢弃概率为 $r$ 时，使用 $M_{ij} \sim \text{Bernoulli}(1-r)$，并计算 $\widetilde{A}_{ij} = A_{ij} M_{ij}/(1-r)$。反向传播复用同一缩放掩码，验证和测试时关闭 Dropout。正则化能够限制拟合，但强度过大也可能导致拟合不足。

优化器根据梯度更新参数。SGD 的基本更新为 $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \boldsymbol{g}$，其中 $\eta$ 为学习率。其余方法通过历史梯度或自适应尺度调整更新，见表2.2。Adam 与 Adamax 采用 $\beta_1 = 0.9, \beta_2 = 0.999$，自适应优化器分母稳定常数为 $10^{-8}$。优化器效果同时依赖学习率，不能只凭算法名称判断优劣。

表 2.2　七类优化器的基本思想

| 优化器 | 更新特点 |
|---|---|
| SGD | 直接沿当前负梯度更新。 |
| Momentum | 累积历史梯度方向，动量系数 $\mu = 0.9$。 |
| Nesterov | 使用动量修正方向 [7]；实际实现为 $\boldsymbol{v}_t = \mu\boldsymbol{v}_{t-1} + \boldsymbol{g}_t$，$\boldsymbol{\theta}_t = \boldsymbol{\theta}_{t-1} - \eta(\boldsymbol{g}_t + \mu\boldsymbol{v}_t)$，不额外计算前瞻位置的梯度。 |
| AdaGrad | 累积平方梯度，对各参数自适应缩放学习率 [8]。 |
| RMSProp | 对平方梯度作指数平均，衰减系数 $\rho = 0.9$。 |
| Adam | 结合一、二阶矩估计并作偏差修正 [9]。 |
| Adamax | 使用一阶矩和无穷范数尺度，是 Adam 的变体 [9]。 |

## 2.4　NumPy 系统实现

系统由数据、网络、优化器、训练与工具模块组成，职责见表2.3。NumPy 负责矩阵计算，Python 标准库负责配置和文件处理，Matplotlib 用于已有图表。

表 2.3　系统模块与职责

| 模块 | 职责 |
|---|---|
| `src/data/` | 读取 MNIST/CIFAR-10、固定数据划分与按批预处理。 |
| `src/nn/` | Dense、ReLU、Dropout、MLP、五类损失及权重正则化。 |
| `src/optim/` | 七类优化器及各参数的更新状态。 |
| `src/training/` | 训练、统一评估和最佳模型参数保存与加载。 |
| `src/utils/` | 日志、实验配置记录和图表工具。 |

数据加载后先划分训练与验证集，再按批转为 float32 并预处理。Dense 用矩阵乘法和偏置广播完成前向计算；ReLU 和 Dropout 保存反向传播所需掩码。损失模块统一返回数据损失与 logits 梯度，MLP 逆序计算各层梯度，再累加 L1/L2 梯度，由优化器更新参数。

每轮训练打乱训练样本，依次执行前向、反向和更新。尾批按实际样本数计算，轮末关闭 Dropout，分别评估训练和验证集。训练时不读取测试集。最佳参数按验证准确率最高、验证 CE 最低、轮次最早的顺序选择，但训练仍执行完整轮数；最终评价重载最佳参数。系统支持实验配置记录、训练日志保存以及模型参数的保存和加载。

已有验证记录中，40 项功能测试均通过。float64 中心差分检查的步长为 $10^{-5}$，五类损失最大绝对梯度误差不超过 $1.10 \times 10^{-11}$，正则项为 $4.56 \times 10^{-11}$，完整小型 MLP 参数为 $2.78 \times 10^{-11}$，均满足原定误差门槛。三类二维高斯簇的 500 步玩具拟合达到 100% 训练准确率，用于检查训练链路。

# 第三章　实验设置

## 3.1　数据集与预处理

MNIST 包含十类 $28 \times 28$ 灰度数字图像 [10]，CIFAR-10 包含十类 $32 \times 32$ RGB 自然图像 [11]。从官方训练集分层划出验证集，划分种子为 20261011，所有对照共享该划分。CIFAR-10 标准化统计仅从训练集拟合，验证与测试复用这些统计。实验不使用图像增强。**Batch 策略对照只使用 MNIST 的 5,000 个训练子集样本**，验证集仍为独立的 5,000 个样本，不能与全量训练结果混为同一条件。

表 3.1　数据划分与预处理

| 数据集 | 训练 | 验证 | 测试 | 输入处理 |
|---|---|---|---|---|
| MNIST | 55,000 | 5,000 | 10,000 | 展平为 784 维，除以 255 |
| CIFAR-10 | 45,000 | 5,000 | 10,000 | RGB 标准化，展平为 3,072 维 |

## 3.2　网络结构与训练参数

两种数据集均使用双隐藏层 MLP，主要参数见表3.2。基准采用 CE 和 SGD，不启用正则化；初始化种子为 42。已有正式训练环境为 macOS 15.7.3、x86_64、8 个逻辑 CPU，CPython 3.12.13、NumPy 2.5.4，使用 Accelerate BLAS/LAPACK 与 float32 数组。耗时为训练器墙钟时间，包括批预处理、更新、轮末评估和参数保存，不包括数据初始加载与训练后绘图。

表 3.2　基准网络与主要训练参数

| 项目 | MNIST | CIFAR-10 |
|---|---|---|
| 网络维度 | $784 \to 128 \to 64 \to 10$ | $3072 \to 256 \to 128 \to 10$ |
| 参数量（含偏置） | 109,386 | 820,874 |
| 隐藏激活 / 输出 | ReLU / logits | ReLU / logits |
| 损失 / 优化器 | CE / SGD | CE / SGD |
| 基准学习率 | 0.05 | 0.01 |
| Batch Size / Epoch | 128 / 12 | 128 / 15 |

## 3.3　对照设计与评价指标

实验记录共 47 次运行，包括 37 项主要配置及 10 次额外种子复验。对照变量见表3.3；除指定变量外，MNIST 主要方法对照保持网络、划分、批大小和 12 轮预算一致。优化器学习率候选为：SGD 0.05/0.1；Momentum、AdaGrad、Nesterov 0.01/0.05；RMSProp 0.001/0.01；Adam、Adamax 0.001/0.003。损失与正则化对照沿用基准学习率，未分别全面调参。

表 3.3　对照实验的实际变量

| 对照 | 配置 |
|---|---|
| 损失函数 | CE、Softmax-MSE、平滑 CE $(\epsilon = 0.1)$、Hinge $(\Delta = 1)$、Focal $(\gamma = 2, \alpha = 1)$。 |
| 正则化 | L1：$10^{-6}, 10^{-5}, 10^{-4}$；L2：$10^{-5}, 10^{-4}, 10^{-3}$；Dropout：0.1、0.2、0.4；L1 $10^{-5}$+L2 $10^{-4}$；L2 $10^{-4}$+Dropout 0.2。 |
| 优化算法 | SGD、Momentum、AdaGrad、RMSProp、Adam、Nesterov、Adamax，各比较两项学习率。 |
| Batch 策略 | 5,000 个训练样本；批大小 1、128、5,000；SGD 0.05；10 轮。 |
| CIFAR-10 扩展 | Momentum 0.01、Adam 0.001、SGD 0.01+L2 $10^{-4}$、SGD 0.01+Dropout 0.2；均为 15 轮。 |
| 种子复验 | MNIST 基准、Momentum 0.05、Focal、L2+Dropout、CIFAR Adam；初始化种子 42、101、202，划分不变。 |

主要评价指标为分类准确率（Accuracy）与真实未平滑标签的 CE。Gap 为最佳验证轮次的评估态训练准确率减去验证准确率。准确率用百分数，差值、Gap 和标准差用百分点；原图纵轴部分使用 $[0, 1]$ 比例。优化效率还记录更新数、总遍历量、完整运行耗时及首次在轮末达到 97% 验证准确率的累计更新数 $U_{97}$。三种子均值与样本标准差直接沿用已有汇总。

# 第四章　实验结果与分析

除明确标为测试的指标外，本章方法比较均使用最佳验证轮次结果。训练准确率与 Gap 取同一轮次，表格保留原始结果的舍入精度。

为便于区分不同实验配置，本文采用统一的实验编号。编号前缀 `B`、`L`、`R`、`O`、`D`、`C` 分别表示基准实验（Baseline）、损失函数对照（Loss）、正则化对照（Regularization）、优化算法对照（Optimizer）、Batch 策略比较和 CIFAR-10 扩展实验。后缀用于标识具体方法、数据集或超参数。例如，`B-M` 和 `B-C` 分别表示 MNIST 与 CIFAR-10 基准实验，`D-ONLINE` 表示在线梯度下降实验，`C-ADAM` 表示 CIFAR-10 上采用 Adam 优化器的实验。上述编号仅作为实验配置标识，不代表新的算法名称。

## 4.1　基准实验

采用第三章的基准网络和训练参数，结果见表4.1。MNIST 在第 10 轮取得 96.90% 验证准确率，测试准确率为 96.83%，训练与验证差距为 0.57 个百分点，说明双隐藏层 MLP 能较好完成数字分类。

表 4.1　基准实验：最佳验证轮次与最终测试

| 数据集 | 运行 | 轮次 | 训练/% | 验证/% | 测试/% | 测试 CE |
|---|---|---|---|---|---|---|
| MNIST | B-M | 10 | 97.47 | 96.90 | 96.83 | 0.1056 |
| CIFAR-10 | B-C | 14 | 66.04 | 51.50 | 50.39 | 1.4425 |

训练准确率对应最佳验证轮次；验证集用于选模，测试集用于最终评价。

CIFAR-10 在第 14 轮取得 51.50% 验证准确率，测试准确率为 50.39%，训练准确率为 66.04%，Gap 达 14.54 个百分点。自然图像的背景与外观变化较复杂，展平像素 MLP 在当前设置下存在明显泛化差距。两个任务的预处理和网络宽度也不同，不能仅由两组数字分离各因素的作用。

表4.2集中列出后续四项代表模型的测试结果。它们由验证集选择后评估，其他未测试配置不补填测试指标。

表 4.2　验证选择确定后四项代表模型的最终测试

| 运行 | 验证/% | 验证 CE | 测试/% | 测试 CE |
|---|---|---|---|---|
| L-HINGE-1 | 97.46 | 0.1772 | 97.63 | 0.1703 |
| R-DROP-0.1 | 96.88 | 0.1028 | 97.05 | 0.0936 |
| O-NAG-0.05 | 98.30 | 0.0844 | 97.98 | 0.0820 |
| C-MOM | 52.16 | 1.4554 | 50.63 | 1.4544 |

每项对应验证集选出的最佳参数快照；C-MOM 为 CIFAR-10，其余为 MNIST。

## 4.2　损失函数对照

本组保持 MNIST 基准网络、SGD 0.05、批大小 128 和 12 轮训练，改变训练目标，结果见表4.3。图4.1展示已有逐轮验证准确率曲线。

表 4.3　MNIST 五类损失的统一验证指标

| 运行 | 训练目标 | 验证/% | 验证 CE | 轮次 |
|---|---|---|---|---|
| B-M | CE | 96.90 | 0.1142 | 10 |
| L-MSE | Softmax-MSE | 93.68 | 0.2366 | 12 |
| L-LS-0.1 | 平滑 CE ($\epsilon = 0.1$) | 97.02 | 0.2166 | 12 |
| L-HINGE-1 | Hinge ($\Delta = 1$) | 97.46 | 0.1772 | 12 |
| L-FOCAL-G2 | Focal ($\gamma = 2$) | 96.52 | 0.1764 | 12 |

验证 CE 均使用真实未平滑标签，不是各方法原始训练目标。

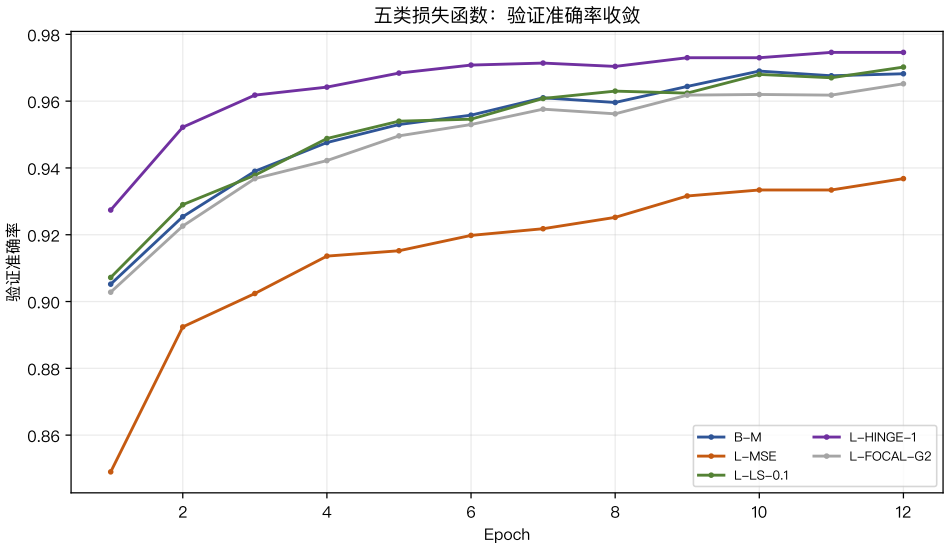



图 4.1　五类损失函数的逐轮验证准确率；纵轴使用比例。

Hinge 的验证准确率为 97.46%，比 CE 高 0.56 个百分点，测试准确率为 97.63%；但其验证 CE 为 0.1772，高于基准的 0.1142。Hinge 优化类别分数间隔，并不直接优化对数概率，因此准确率较高不意味着全部指标更优。

Softmax-MSE 的验证准确率仅为 93.68%。其梯度经过 Softmax Jacobian，在概率接近饱和时可能较弱，与当前预算下收敛较慢的现象相容。标签平滑准确率略高于 CE，但真实标签 CE 为 0.2166；Focal 为 96.52%，也未超过 CE。该对照没有为每种损失单独搜索学习率或延长训练，结果只说明当前配置的表现，不构成损失函数的普遍排名。

图4.2补充各损失自身的训练目标变化，帮助观察收敛过程。各面板的损失定义与尺度不同，曲线下降只表示相应训练目标在改善，不能按绝对数值跨方法排名。

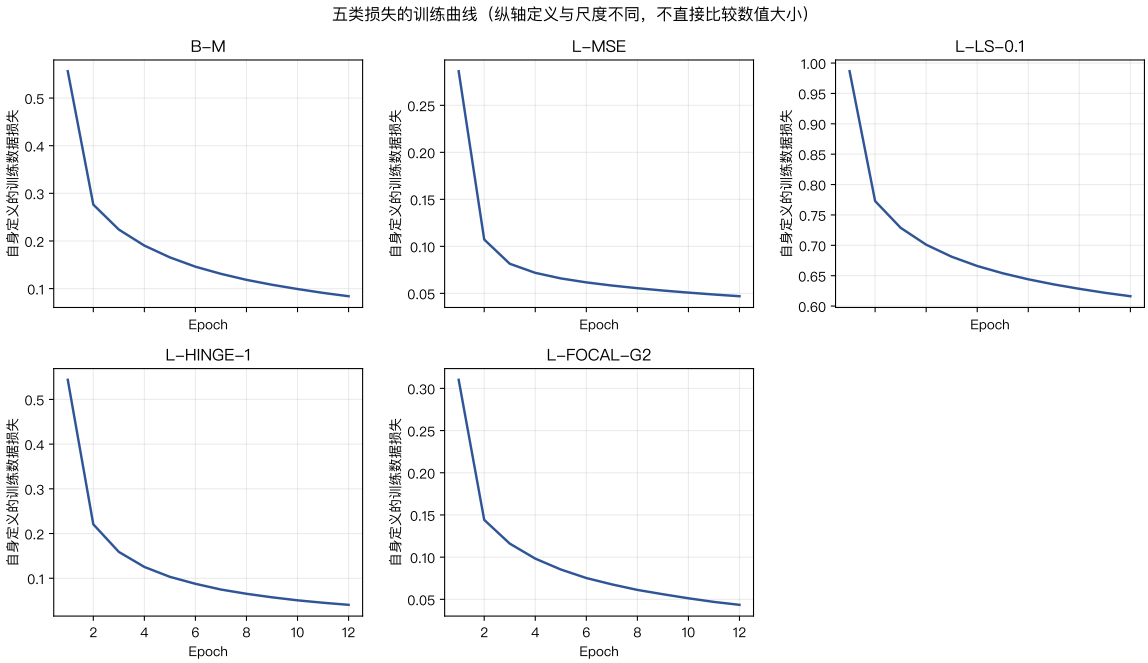



图 4.2　五类损失各自的训练目标曲线；各面板纵轴定义和尺度不同。

## 4.3　正则化对照

正则化实验保持 MNIST 基准训练设置，比较 L1、L2、Dropout 及两种组合。表4.4保留所有强度与组合的结果。

表 4.4　MNIST 正则化强度与组合对照

| 运行 | 方法及强度 | 验证/% | 验证 CE | Gap/百分点 |
|---|---|---|---|---|
| B-M | 无正则 | 96.90 | 0.1142 | 0.57 |
| R-L1-1E6 | L1 $10^{-6}$ | 96.84 | 0.1097 | 0.86 |
| R-L1 | L1 $10^{-5}$ | 96.84 | 0.1059 | 1.00 |
| R-L1-1E4 | L1 $10^{-4}$ | 96.80 | 0.1139 | 0.72 |
| R-L2-1E5 | L2 $10^{-5}$ | 96.84 | 0.1052 | 1.03 |
| R-L2 | L2 $10^{-4}$ | 96.82 | 0.1106 | 0.85 |
| R-L2-1E3 | L2 $10^{-3}$ | 96.78 | 0.1131 | 0.71 |
| R-DROP-0.1 | Dropout 0.1 | 96.88 | 0.1028 | 0.90 |
| R-DROP | Dropout 0.2 | 96.66 | 0.1049 | 0.85 |
| R-DROP-0.4 | Dropout 0.4 | 95.94 | 0.1295 | 0.84 |
| R-ELASTIC | L1 $10^{-5}$+L2 $10^{-4}$ | 96.88 | 0.1152 | 0.57 |
| R-L2DROP | L2 $10^{-4}$+Dropout 0.2 | 96.62 | 0.1056 | 0.86 |

Gap 由最佳验证轮次的评估态训练准确率减去验证准确率得到。

三种 L1 和三种 L2 均未超过无正则基准的 96.90%；较大惩罚强度也未带来更好的验证准确率。MNIST 基准 Gap 本来较小，增加约束并不必然改善分类效果。

Dropout 丢弃概率从 0.1 增至 0.2、0.4 时，验证准确率依次为 96.88%、96.66%、95.94%。$r = 0.4$ 的训练准确率也降至 96.78%，呈现当前预算下拟合不足的迹象。Elastic Net 为 96.88%，L2+Dropout 为 96.62%，组合并未提高准确率。

新增候选中，Dropout 0.1 与 Elastic Net 准确率并列，但前者验证 CE 更低，因此选为代表模型。其测试准确率为 97.05%，测试 CE 为 0.0936；验证准确率仍未超过基准，且没有该配置的三种子复验，不能据此认定稳定改进。Gap 需要结合准确率和 CE 解释，差距较小也可能只是训练拟合受限。

## 4.4 优化算法对照

七类优化器使用相同网络、数据、批大小和 12 轮预算，各从第三章列出的两项学习率中按验证规则选择。表4.5报告所选结果，图4.3比较其验证准确率随更新数的变化。

表 4.5　MNIST 各优化器按验证规则选出的候选

| 优化器 | 学习率 | 验证/% | 验证 CE | 轮次 | $U_{97}$ | 时间/s |
|---|---|---|---|---|---|---|
| SGD | 0.1 | 97.56 | 0.0847 | 11 | 3010 | 12.20 |
| Momentum | 0.05 | 98.08 | 0.0768 | 11 | 1290 | 13.55 |
| AdaGrad | 0.01 | 97.46 | 0.0854 | 12 | 3010 | 12.47 |
| RMSProp | 0.001 | 98.06 | 0.0766 | 12 | 1720 | 20.78 |
| Adam | 0.003 | 97.84 | 0.0866 | 7 | 1290 | 18.01 |
| Nesterov | 0.05 | 98.30 | 0.0844 | 12 | 1290 | 19.37 |
| Adamax | 0.003 | 97.78 | 0.0764 | 12 | 1720 | 20.49 |

$U_{97}$ 为首次在轮末达到 97% 验证准确率的累计更新数，时间为完整运行耗时。

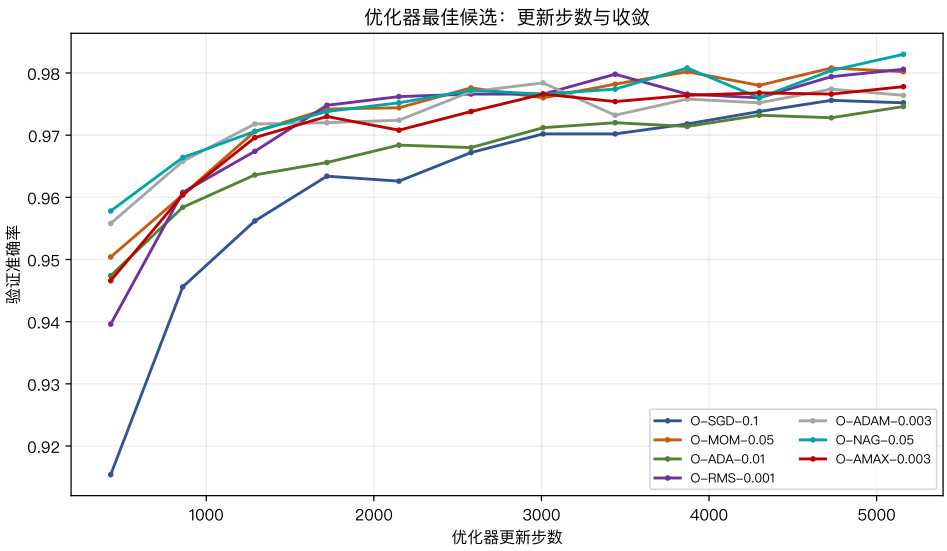



图 4.3　各优化器所选候选的验证准确率与累计更新数；观测点为轮末评价。

Nesterov 0.05 的验证准确率为 98.30%，相比原始 SGD 0.05 基准的 96.90% 提高了

1.40 个百分点；相比本节优化器对照中选出的 SGD 0.1（97.56%）提高了 0.74 个百分点。其测试准确率为 97.98%。Momentum 和 RMSProp 分别达到 98.08% 和 98.06%；Adam 为 97.84%，Adamax 为 97.78%。这是有限候选中的表现，不代表各算法充分调参后的上限。

学习率影响明显：Nesterov 0.01 为 97.44%，0.05 为 98.30%；RMSProp 0.001 为 98.06%，0.01 却仅为 97.20%，最佳轮次为第 4 轮。高学习率 RMSProp 第 12 轮验证 CE 升至 0.2555，高于最佳轮次的 0.1453，保留了训练波动与退化的观测。AdaGrad 两项候选准确率同为 97.46%，因 0.01 的 CE 更低而选择该学习率。

Momentum、Adam、Nesterov 首次在第 3 轮达到 97% 验证准确率，即 1,290 次更新；SGD 与 AdaGrad 需 3,010 次。Momentum 完整运行约 13.55 s，Adam 约 18.01 s，Nesterov 约 19.37 s。动量方法在此设置下较快达到较高准确率，但相同更新数不等于相同耗时，单次时间只反映当前主机观测。

准确率与 CE 排序仍有差异：Adamax 的验证 CE 为 0.0764，Momentum 为 0.0768，均低于 Nesterov 的 0.0844。本文按准确率选模，同时报告 CE 与耗时。

## 4.5 Batch 策略比较

本组只用固定的 5,000 个 MNIST 训练子集样本，SGD 学习率为 0.05，均训练 10 轮；独立验证集仍为 5,000 个样本。结果见表4.6。

表 4.6　MNIST 5,000 样本子集的 Batch 策略对照

| 运行 | 批大小 | 遍历量 | 更新数 | 时间/s | 验证/% | 验证 CE |
|---|---|---|---|---|---|---|
| D-ONLINE | 1 | 50000 | 50000 | 43.44 | 91.68 | 0.4045 |
| D-MINI | 128 | 50000 | 400 | 1.07 | 89.02 | 0.3529 |
| D-BATCH | 5000 | 50000 | 10 | 1.21 | 39.48 | 1.9624 |

三组均执行 10 轮，学习率为 0.05。最佳验证轮次分别为 8、10、10；表中更新数与时间均为完整运行值。

三组总遍历量均为 50,000，更新数却分别为 50,000、400、10。Online 准确率最高，为 91.68%，但耗时约 43.44 s；Mini-batch 达 89.02%，仅耗时 1.07 s，在当前主机上兼顾了性能和效率。Batch 只有十次更新，验证准确率为 39.48%，体现当前学习率和预算下的拟合不足。

这不是等更新数或等时间比较，也未为不同批大小分别调参，不能据此断言 Online 普遍更优或全批梯度无法学习。Online 的验证 CE 为 0.4045，高于 Mini-batch 的 0.3529，说明准确率与概率损失仍需同时观察。

## 4.6 CIFAR-10 扩展与简要讨论

本组沿用 CIFAR-10 网络、批大小 128 和 15 轮预算，改变优化器或正则化，具体参数见第三章，结果见表4.7。

表 4.7　CIFAR-10 扩展实验的最佳验证轮次指标

| 运行 | 方法 | 训练/% | 验证/% | 验证 CE | Gap/百分点 |
|---|---|---|---|---|---|
| B-C | SGD | 66.04 | 51.50 | 1.4449 | 14.54 |
| C-MOM | Momentum | 67.19 | 52.16 | 1.4554 | 15.03 |
| C-ADAM | Adam | 77.37 | 52.06 | 1.6560 | 25.31 |
| C-L2 | SGD+L2 $10^{-4}$ | 64.83 | 51.00 | 1.4439 | 13.83 |
| C-DROP | SGD+Dropout 0.2 | 57.93 | 51.42 | 1.4005 | 6.51 |

同一网络、批大小 128、15 轮预算。

Momentum 0.01 的验证准确率为 52.16%，比基准高 0.66 个百分点，所选模型测试准确率为 50.63%。Adam 为 52.06%，L2 为 51.00%，Dropout 为 51.42%。Momentum 的测试值较基准高 0.24 个百分点，但单次小幅差异不代表稳定优势。

Adam 的训练准确率为 77.37%，Gap 达 25.31 个百分点，验证 CE 为 1.6560，均显示较明显的过拟合。第 15 轮训练准确率继续升至 77.77%，验证准确率降至 51.14%，CE 升至 1.7268；主表仍使用验证所选第 14 轮，不以末轮代替最佳结果。

Dropout 将 Gap 降到 6.51 个百分点，验证 CE 为本组最低的 1.4005，但准确率未超过基准。L2 也未提高准确率。正则化在这里限制了训练拟合，却没有带来一致的分类收益。展平像素网络不显式利用局部邻域和权重共享，约 50% 的测试表现体现了当前方案的限制；本文没有 CNN 对照，不能给出两类架构的实验排名。

表4.8与图4.4将三种子结果集中呈现。Momentum 的均值高于 MNIST 基准，Focal 与 L2、Dropout 组合的均值未超过基准；CIFAR Adam 的标准差为 0.580 个百分点，大于本次 MNIST 代表配置。仅有三次观测，这些数字用于描述变化，不支持显著性判断，也不能替代 Hinge、Nesterov、Dropout 0.1 和 CIFAR Momentum 尚未进行的种子复验。

表 4.8　固定划分下三随机种子的验证准确率

| 配置组 | seed 42/% | seed 101/% | seed 202/% | 均值/% | 标准差/百分点 |
|---|---|---|---|---|---|
| MNIST 基准 | 96.90 | 96.86 | 96.70 | 96.820 | 0.106 |
| Momentum | 98.08 | 97.80 | 97.78 | 97.887 | 0.168 |
| Focal | 96.52 | 96.34 | 96.20 | 96.353 | 0.160 |
| L2+Dropout | 96.62 | 96.56 | 96.46 | 96.547 | 0.081 |
| CIFAR Adam | 52.06 | 53.18 | 52.36 | 52.533 | 0.580 |

样本标准差使用 ddof=1。各列种子表示初始化种子；数据划分保持不变。

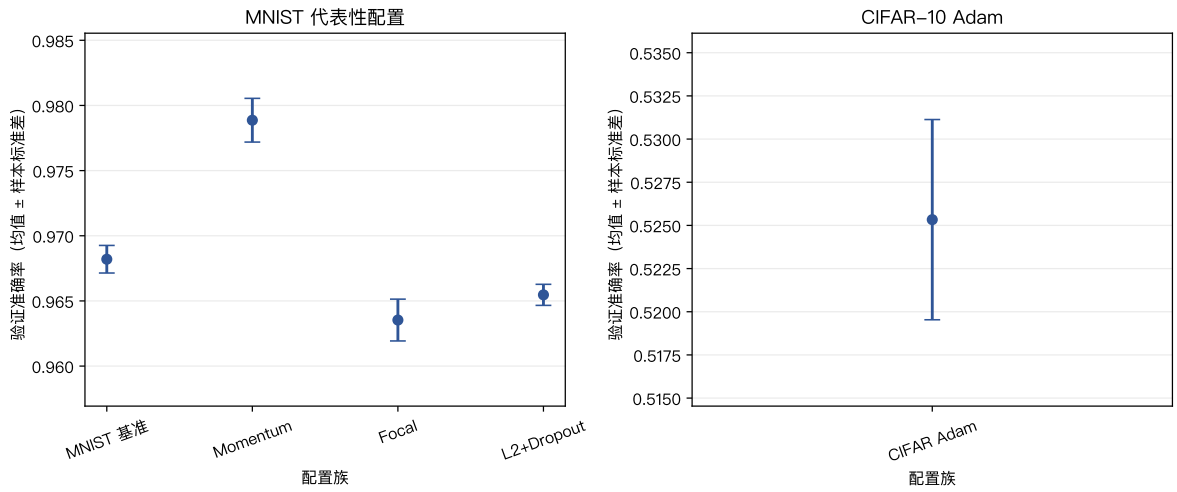



图 4.4　代表配置的三种子验证准确率均值与样本标准差；两个面板纵轴范围不同，误差棒不是置信区间。

# 第五章　总结

本次课程实验用 NumPy 自主实现了双隐藏层全连接网络、前向与反向传播、五类损失函数、正则化及七类优化器，完成 MNIST 与 CIFAR-10 图像分类。已有梯度检查与功能测试支持手写计算的正确性，训练日志和模型参数保留在项目中。

MNIST 基准测试准确率为 96.83%，Hinge 与 Nesterov 代表模型分别为 97.63% 和 97.98%；CIFAR-10 基准为 50.39%，Momentum 为 50.63%。当前 MLP 能较好处理数字分类，在彩色自然图像上仍有明显泛化差距。

方法对照表明，损失函数影响收敛和概率评价，准确率较高不一定意味着 CE 更低；正则化强度过大可能降低拟合，L1/L2/Dropout 未呈现一致的准确率收益；优化器需要与学习率共同选择，动量方法在本次 MNIST 设置下表现较好。Batch 对照还说明，同样的样本遍历量并不代表相同的更新或时间预算。

实验采用固定结构和有限候选，训练轮数与随机种子数量较少，实验记录的解释范围见第三章。因此结论主要是对本次课程实验现象的分析。后续可通过更充分的调参与重复实验检查这些趋势。

# 参考文献


[1] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J/OL]. Nature, 1986, 323(6088): 533-536. https://www.nature.com/articles/323533a0. DOI:10.1038/323533a0.

[2] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep learning[M/OL]. MIT Press, 2016. https://www.deeplearningbook.org/.

[3] HE K M, ZHANG X Y, REN S Q, et al. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification[C/OL]//Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034. https://openaccess.thecvf.com/content_iccv_2015/html/He_Delving_Deep_into_ICCV_2015_paper.html.

[4] GLOROT X, BENGIO Y. Understanding the difficulty of training deep feedforward neural networks[C/OL]//Proceedings of Machine Learning Research: v.9 Proceedings of the thirteenth international conference on artificial intelligence and statistics. PMLR, 2010: 249-256. https://proceedings.mlr.press/v9/glorot10a.html.

[5] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C/OL]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988. https://openaccess.thecvf.com/content_iccv_2017/html/Lin_Focal_Loss_for_ICCV_2017_paper.html.

[6] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J/OL]. Journal of Machine Learning Research, 2014, 15(56): 1929-1958. https://jmlr.org/papers/v15/srivastava14a.html.

[7] SUTSKEVER I, MARTENS J, DAHL G, et al. On the importance of initialization and momentum in deep learning[C/OL]//Proceedings of Machine Learning Research: v.28 Proceedings of the 30th international conference on machine learning. PMLR, 2013: 1139-1147. https://proceedings.mlr.press/v28/sutskever13.html.

[8] DUCHI J, HAZAN E, SINGER Y. Adaptive subgradient methods for online learning and stochastic optimization[J/OL]. Journal of Machine Learning Research, 2011, 12(61): 2121-2159. https://jmlr.org/papers/v12/duchi11a.html.

[9] KINGMA D P, BA J. Adam: a method for stochastic optimization[C/OL]//Proceedings of the 3rd international conference on learning representations. 2015. https://arxiv.org/abs/1412.6980.

[10] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J/OL]. Proceedings of the IEEE, 1998, 86(11): 2278-2324. https://ieeexplore.ieee.org/document/726791. DOI:10.1109/5.726791.

[11] KRIZHEVSKY A. The CIFAR-10 and CIFAR-100 datasets[EB/OL]. [2026-10-12]. https://www.cs.toronto.edu/~kriz/cifar.html.

# 附录 A　复现资料与 AI 辅助说明

完整训练配置、逐轮日志、参数快照、47 次运行汇总及全部优化器候选仍保留在项目实验资料中；本报告只展示与分析有关的结果，不逐项打印全部运行。代码仓库为：

https://github.com/kaikailuo/numpy-mlp-classification

报告工程的 `evidence/` 目录保留实验汇总、重复统计与测试记录；完整复现方法见仓库 README。复现时应沿用原配置和固定数据划分，区分模型参数重载与重新训练。

本项目使用 ChatGPT/Codex 辅助技术方案设计、代码实现、实验审查及报告整理。实验数据和性能指标均来自实际运行记录，最终提交内容由作者核验并负责。